

Aumento de datos controlado en CIFAR-10

Misma CNN, misma partición, siete condiciones de entrenamiento. La prueba oficial solo se usa para medir.

La pregunta es concreta. En el Momento 3 la red ya traía reflejo horizontal, rotación y zoom. Aquí la referencia es esa misma red sin ese bloque, y *full* lo vuelve a poner. Además se entrena cada transformación por separado, más dos sondas que pueden romper la etiqueta: reflejo vertical y desenfoque gaussiano. Todo lo demás queda fijo.

Protocolo

Pieza	Decisión
Datos	CIFAR-10 local, $32 \times 32 \times 3$. Entrenamiento oficial 50 000; prueba oficial 10 000.
Partición	80/20 estratificada del entrenamiento oficial, semilla 42: 40 000 / 10 000. La prueba oficial no entra al entrenamiento.
Red	CNN del Momento 3. La referencia quita el bloque estocástico. 290 090 parámetros en las siete condiciones.
Entrenamiento	Adam, tasa 10^{-3} , entropía cruzada sparse, lote 128. Tope 30 épocas. EarlyStopping sobre val_loss, paciencia 6, restaura los mejores pesos. ReduceLROnPlateau, factor 0,5, paciencia 2.
Aumento	Dentro del modelo y solo con training=True. Una semilla (42) por condición.

Las siete condiciones son *reference* (sin transformación), *full* (reflejo horizontal + rotación $\pm 36^\circ$ + zoom 10 %), *flip_h*, *rotation*, *zoom*, *flip_v* y *blur* (sigma entre 0,5 y 1,5). La regla de ablación, fijada de antemano, llama útil a un cambio de F1 macro mayor que +0,5 puntos, perjudicial a uno menor que -0,5, y neutro al intervalo cerrado entre ambos. Es una etiqueta descriptiva, no una prueba estadística.

Qué hay en los datos

Las diez clases quedan en 4 000 / 1 000 / 1 000. Ninguna clase pesa más que otra en la comparación. El rango de píxeles del lote oficial es 0–255; después de dividir por 255 queda en [0, 1]. A 32×32 un borde ocupa pocos píxeles, y una transformación que lo borre cambia lo que la red puede usar.

La varianza del Laplaciano, tomada solo como proxy de nitidez, no es pareja. Automóvil (media 3 346) y camión (3 271) salen más nítidos que pájaro (1 817) y ciervo (1 877). Avión es la clase más clara (brillo medio 0,56) y rana la más oscura (0,42). El contraste más alto es el de camión (0,25) y el más bajo el de ciervo (0,18). La desviación intra-clase de los píxeles es mayor en automóvil (0,26) que en ciervo (0,21): hay clases más homogéneas que otras aunque el conteo sea el mismo.

Un cribado pHash entre las 50 000 imágenes oficiales de entrenamiento y las 10 000 de prueba encontró 117 pares con distancia de Hamming menor o igual a 4. Los 117 comparten clase: 4 a distancia 0, 39 a distancia 2 y 74 a distancia 4. Automóvil reúne 34 pares y rana 20. Siguen siendo candidatos. Confirmarlos pide mirar el par y comparar píxeles, empezando por los cuatro de distancia 0. Si alguno es casi la misma foto, sube un poco la exactitud de todos los modelos, porque la prueba es la misma.

Resultados en la prueba oficial

Condición	Exactitud	F1 macro	Δ exact.	Δ F1	Épocas	Mejor
reference	83,75 %	0,837	0	0	30	30
full	74,06 %	0,735	-9,69	-10,20	30	25
flip_h	83,89 %	0,838	+0,14	+0,09	30	29
rotation	77,06 %	0,766	-6,69	-7,11	30	26
zoom	80,70 %	0,805	-3,05	-3,23	30	28
flip_v	76,06 %	0,759	-7,69	-7,83	30	30
blur	53,39 %	0,506	-30,36	-33,08	8	2

Tabla 1. Exactitud y F1 macro en la prueba oficial (10 000 imágenes). Los deltas están en puntos porcentuales frente a la referencia. «Mejor» es la época de menor pérdida de validación; con EarlyStopping se evalúa ese punto, no la última época.

full queda en 74,06 % de exactitud y 0,735 de F1 macro, 9,69 y 10,20 puntos por debajo de la referencia (83,75 % y 0,837). La referencia usa las 30 épocas y la época 30 es su mejor pérdida de validación. *full* tiene la mejor época en la 25 y también llega a 30, así que el paro temprano no se activa. En esa época 25 la exactitud de entrenamiento es 72,82 % y la de validación 74,76 %. La referencia, en la época 30, está en 85,99 % y 83,89 %.

La brecha (exactitud de entrenamiento menos exactitud de validación, en la mejor época) es de +2,1 puntos en la referencia y de -1,9 en *full*. La validación de *full* queda por encima del entrenamiento porque el lote de entrenamiento está deformado y la validación no. Esa brecha negativa convive con una prueba peor. Dentro de cada escenario, prueba y validación se parecen: 74,06 % frente a 74,76 % en *full*, y 83,75 % frente a 83,89 % en la referencia. La diferencia entre condiciones se ve en los dos conjuntos.

Curvas de entrenamiento




Figura 1. Pérdida y exactitud por época. Línea continua: entrenamiento. Línea punteada: validación. El desenfoque se corta en la época 8; el resto llega al tope de 30.

Dónde se pierde el F1

El F1 de *full* baja en las diez clases. El descenso grande está en animales. Gato pasa de 0,699 a 0,549 (recall 0,692 a 0,464), perro baja 14,9 puntos (recall 0,762 a 0,498) y rana 14,5. En rana el recall sube de 0,909 a 0,934 y la precisión cae de 0,829 a 0,588: el modelo predice rana 1 589 veces, con 655 falsos positivos, frente a 188 en la referencia. Los cruces fuera de la diagonal lo concentran: gato→rana 219, pájaro→rana 132, ciervo→rana 121 y perro→rana 109. En la referencia el cruce principal sigue siendo perro↔gato (132 y 127). Automóvil y barco pierden menos F1 (4,0 y 4,4 puntos).

Los ejemplos de alta confianza piden una lectura fina. Varios errores llamativos de *full* ya lo eran en la referencia. El gato del índice 2405 lo clasifican rana los dos modelos, la referencia con probabilidad 1,00. El caballo 8981 pasa a ciervo en los dos. Hay casos al revés: el camión 8218 lo clasifica bien la referencia (0,94) y *full* lo manda a rana con probabilidad 0,98. El ciervo 6016 también lo acierta la referencia y *full* lo llama rana (0,98). El patrón agregado, más que un solo recuadro, es el salto de falsos positivos hacia rana.




Figura 2. Matrices de confusión normalizadas por clase real. En el aumento completo la columna de rana se carga con gato, pájaro, ciervo y perro.




Figura 3. Cambio de F1 por clase, aumento completo menos referencia, en puntos porcentuales. Las diez barras quedan por debajo de cero.

Transformaciones por separado

Ninguna transformación individual pasa el umbral de $+0,5$ puntos de F1 macro. El reflejo horizontal queda en $+0,09$ (exactitud 83,89 %) y la regla lo marca neutro: es la única condición que se mantiene junto a la referencia, 0,14 puntos de exactitud por encima. Rotación ($-7,11$), zoom ($-3,23$), reflejo vertical ($-7,83$) y desenfoque ($-33,08$) quedan como perjudiciales. El bloque completo ($-10,20$) queda por debajo del zoom solo (0,805) y de la rotación sola (0,766).

El reflejo vertical y el desenfoque salen mal en la dirección que sugería la etiqueta. Invertir un animal o un vehículo a esta resolución produce poses que casi no aparecen en la prueba, y el F1 baja 7,83 puntos, cerca de la rotación de $\pm 36^\circ$. El desenfoque es de otra escala: exactitud 53,39 % y F1 macro 0,506. El paro temprano corta en la época 8; la mejor pérdida de validación es la época 2 (exactitud de validación 54,17 %) y en la época 8 la pérdida de validación ya está en 1,88, frente a 0,93 de entrenamiento. Con desenfoque, el F1 más bajo es el de gato (0,19), pájaro (0,32) y ciervo (0,37). Pájaro y ciervo ya tenían el proxy de nitidez más bajo; gato no. Esa medida no ordena por sí sola el daño.




Figura 4. F1 por clase y condición. El reflejo horizontal sigue de cerca a la referencia. Con desenfoque, gato, pájaro y ciervo quedan muy por debajo del resto.

Conclusiones y limitaciones

Con esta red, esta partición, la semilla 42 y un tope de 30 épocas, reincorporar el bloque del Momento 3 baja la prueba. La única transformación individual dentro de la banda neutra es el reflejo horizontal. Rotación, zoom, reflejo vertical y desenfoque quedan del lado perjudicial de la regla de $\pm 0,5$ puntos, y el desenfoque además detiene el entrenamiento. La brecha negativa de *full* va con un entrenamiento más difícil y con una prueba que también baja. La comparación queda atada a este presupuesto de épocas y a una sola semilla.

Tres límites pesan sobre esa lectura. A 32×32 el desenfoque y los giros grandes se comen detalle. Los 117 pares pHash siguen sin confirmar; si algunos son casi duplicados, suben la exactitud de todas las condiciones por igual. La referencia todavía bajaba la pérdida de validación en la época 30, y *full* se estancó hacia la 25. No corrimos más épocas, así que queda abierto si el hueco es de entrenamiento corto. Cada condición se entrenó una sola vez, y el reflejo horizontal, con un cambio de una décima, puede cambiar de signo con otra semilla.

Para comprobarlo repetiría la referencia, *full* y el reflejo horizontal con otras dos o tres semillas, y miraría si el cambio de F1 de *full* se queda cerca de -10 puntos. También revisaría los cuatro pares a distancia 0 y, si hace falta, alargaría el entrenamiento de esas dos condiciones. El aumento de datos no reemplaza un conjunto representativo: las clases ya estaban balanceadas, y las transformaciones que más se alejan de las fotos de prueba son las que más bajan el F1.

Referencias

- Krizhevsky, A. (2009). *Learning Multiple Layers of Features from Tiny Images*. University of Toronto. <https://www.cs.toronto.edu/~kriz/learning-features-2009-TR.pdf>
- Barz, B. y Denzler, J. (2020). Do we train on test data? Purging CIFAR of near-duplicates. *IEEE/CVF WACV*.
- TensorFlow. Data augmentation. https://www.tensorflow.org/tutorials/images/data_augmentation
- Zhang, A., Lipton, Z. C., Li, M. y Smola, A. J. *Dive into Deep Learning*, capítulo Image Augmentation. https://d2l.ai/chapter_computer-vision/image-augmentation.html